

Proyecto 2

Integrantes:

- Gael Alberto González Guzmán 261768
 - Sergio Alejandro Solís Astorga 262545
 - Emanuel Fernandez Salomé 260094
-

Objetivo del curso:

Diseñar y desarrollar colaborativamente un curso interactivo en swirl que permita aprender, practicar e interpretar los conceptos fundamentales de muestreo y distribuciones muestrales, integrando teoría, ejercicios en R, retroalimentación, referencias académicas y archivos de inicialización reproducibles. Al finalizar el proyecto, el equipo deberá demostrar que puede: diseñar un curso completo en swirl; organizar contenidos estadísticos en una secuencia didáctica; utilizar R para simular y seleccionar muestras; aplicar diferentes métodos de muestreo; trabajar con distribuciones muestrales; utilizar init Lesson.R; documentar las fuentes utilizadas; trabajar colaborativamente mediante GitHub; probar y depurar un curso antes de su entrega.

Organización de las lecciones:

1. Introducción al muestreo
 2. Muestreo aleatorio simple
 3. Muestreo sistemático
 4. Muestreo estratificado
 5. Muestreo conglomerado
 6. Muestreo por conveniencia
 7. Test comparativo
 8. Distribución muestrales media y proporción
 9. Distribución muestral de la varianza
 10. Aplicación integral
-

Tabla que relaciona temas y lecciones.

Tema	Lección
1. Introducción al muestreo	Introduccion_al_muestreo
2. Muestreo aleatorio simple	Muestreo_aleatorio_simple-Test comparativo
3. Muestreo sistemático	Muestreo_sistematico-Test comparativo
4. Muestreo estratificado	Muestreo estratificado-Test comparativo
5. Muestreo conglomerado	Muestreo conglomerado-Test comparativo
6. Muestreo por conveniencia	Muestreo por conveniencia-Test comparativo
7. Distribución muestral de la media.	Distribución muestrales media y proporción.

8. Distribución muestral de la proporción.	Distribución muestrales media y proporción.
9. Distribución muestral de la varianza.	Distribución muestral de la varianza.

Explicación de cada “initLesson.R”:

Muestreo aleatorio simple

- ¿Qué objetos crea?** Crea 3 objetos: `poblacion_microservicios`, `N_poblacional`, y `media_verdadera`.
- ¿Qué información contienen esos objetos?** uidos en 4 capas lógicas (Auth,, Billin
 - `poblacion_microservicios`: Una tabla con 500 servicios divididos en 4 áreas (Auth, Billing, Catalog y Checkout) y su tiempo de respuesta en milisegundos.
 - `N_poblacional`: El número total de filas del data frame, que representan el tamaño de la poblacion ($N = 500$).
 - `media_verdadera`: El promedio real poblacional del tiempo de respuesta redondeado a dos decimales.
- ¿Por qué se inicializan antes de comenzar la lección?** Se inicializan para evitar que el usuario del curso tenga que escribir el código extenso de iniciación lo que permite enfocarse en la teoría y hace que el avance de la lección sea más fluido y rápido.
- ¿En qué actividades se utilizan?**
 - Se usa `poblacion_microservicios` para ver las primeras filas con `head()`.
 - Se usa `media_verdadera` para revisar el promedio exacto de la población.
 - `poblacion_microservicios` también se usa para filtrar los datos con los índices seleccionados.
 - Y tambien se usa `poblacion_microservicios` (Su columna `$tiempo_ms`) dentro de la función `mean()`.
- ¿Se utiliza `set.seed()`? Si ¿Por qué?** Se utiliza para garantizar la reproducibilidad exacta de la generación de datos aleatorios en cualquier computadora donde se ejecute la lección.

Muestreo estratificado

- ¿Qué objetos crea?** Se crea solo un objeto que simula una base de datos llamado `bd_usuarios` es un data frame
- ¿Qué información contienen esos objetos?** contiene 3 columnas, la primera contiene 1000 ids que simulan 1000 usuarios, en la segunda se creó un vector que indica que tipo de suscripción tiene cada uno de los 1000 usuarios, en la tercera igual se crea un vector en el que especifica en qué dispositivo está conectado cada usuario
- ¿Por qué se inicializan antes de comenzar la lección?**
Porque de esta forma cuando el usuario llegue a la actividad en la que se requiere estará lista para usarse y no es necesario que la inicialice el mismo
- ¿En qué actividades se utilizan?** Se utiliza cuando el usuario extrae un estrato de los usuarios pro y cuando saca la muestra de este estrato

5. **¿Se utiliza set.seed()? SI ¿Por qué?** Se utiliza semilla, ya que en la base de datos simulada 'bd_usuarios' se le asigna un valor aleatorio y de esta forma aseguramos que los datos mostrados al estudiante sean exactos con los que hicimos el curso

Muestreo conglomerado

1. **¿Qué objetos crea?** Crea un data frame llamado bd_transacciones que simula una lista de 50 servidores
2. **¿Qué información contienen esos objetos?** Contiene 3 columnas. La primera, contiene números del 1 al 50 simulando 50 servidores, La segunda contiene el nombre de los servidores como Server a,b,c,d,e (10 cada uno) clasificando los servidores en 5 grupos. La tercera contiene el tiempo de transacción de cada servidor(esta columna sólo está para llenar la base de datos, pero no se utiliza y no es relevante para la lección)
3. **¿Por qué se inicializan antes de comenzar la lección?** para que el estudiante tenga acceso a la lista de servidores en el momento que la necesite.
4. **¿En qué actividades se utilizan?** Se utiliza cuando el usuario crea la muestra final con los grupos del server A y C
5. **¿Se utiliza set.seed()?¿Por qué?** No se utiliza, ya que la lección no depende de que los datos sean los mismos cada vez que se corre

Muestreo por conveniencia

6. **¿Qué objetos crea?**
Se creó 'primeras_50', 'resto_población' y respuestas, un data frame que contiene dos columnas una con 1000 ids y la otra con el nombre 'calificacion_producto' que contiene un vector con los primeros dos objetos.
7. **¿Qué información contienen esos objetos?**
'primeras_50' contiene un vector que contiene 50 calificaciones de 4 y 5 al azar
'resto_población' contiene un vector que contiene 950 calificaciones de entre 1 a 3 al azar
'respuestas' es un data frame que contiene dos columnas una con 1000 ids y la otra con el nombre 'calificacion_producto' que contiene un vector con los primeros dos objetos. lo que simula que las primeras 50 calificaciones son muy buenas y el resto no tanto
8. **¿Por qué se inicializan antes de comenzar la lección?**
por que al simular ser una base de datos es necesario que el alumno la tenga disponible cuando la necesite
9. **¿En qué actividades se utilizan?**
Se utiliza en diferentes partes primero el usuario utiliza la función head() para tomar los primeros 50 datos de respuestas. después de estos se saca el promedio de los primeros 50 para que el alumno piense que las calificaciones son buenas. Después se saca el promedio de los 1000 datos, como 950 de estas calificaciones son de 1 a 3 le dará un promedio más bajo y quedará evidenciado cómo puede haber sesgos en las muestras
10. **¿Se utiliza set.seed()?¿Por qué?**
Así es, ya que en la lección usamos nombramos datos que necesitamos que se repliquen para que coincidan

Distribución muestrales media y proporción:

1. **¿Qué objetos crea?** Crea 4 objetos: `poblacionTiempos`, `poblacionPeticones`, `peticonesServidor` y `N`.
2. **¿Qué información contienen esos objetos?**
 - `poblacionTiempos`: 1000 tiempos de ejecución en milisegundos, con una distribución normal con media de 250 y desviación de 30.
 - `poblacionPeticones`: 1000 peticiones HTTP binarias (1= éxito, 0 =falla) con 88% de éxito.
 - `peticonesServidor`: 10000 peticiones binarias al servidor con 85% de éxito, casi lo mismo que el anterior objeto.
 - `N`: El tamaño escalar de la población ($N = 1000$).
3. **¿Por qué se inicializan antes de comenzar la lección?** Porque actúan como las “poblaciones marco” fijas sobre las cuales los usuarios sacarán muestras aleatorias durante los ejercicios. Al declararlas en el `initLesson.R`, esos vectores siempre existirán cuando se ejecute la lección.
4. **¿En qué actividades se utilizan?**
 - `poblacionTiempos`: En la distribución muestral de la media, para extraer muestras con `sample()`, calcular promedios y analizar la variabilidad que sale.
 - `poblacionPeticones` y `peticonesServidor`: En la distribución muestral de la proporción, para calcular la proporción de éxitos en distintas muestras.
 - `N`: Como constante de referencia para el tamaño de la población.
5. **¿Se utiliza `set.seed()`?** Si **¿Por qué?** Para asegurarme de que R genere exactamente las mismas poblaciones aleatorias aunque se ejecute varias veces.

Distribución muestral de la varianza:

1. **¿Qué objetos crea?** Crea un solo objeto: `poblacionTiempos`.
2. **¿Qué información contienen esos objetos?** El vector de ‘`poblacionTiempos`’ tiene 5000 datos que representan tiempos (En milisegundos), simulados con una distribución normal de media 150 y desviación estándar de 14.14, lo que genera una varianza de aproximadamente 200.
3. **¿Por qué se inicializan antes de comenzar la lección?** Para asegurar que la población de datos exista en la lección desde el inicio, y para ahorrar tiempo creando cada vez.
4. **¿En qué actividades se utilizan?** Se utiliza `poblacionTiempos` en las actividades de la distribución muestral de la varianza, donde el alumno extrae muestras con `sample()`, calcula la varianza muestral s^2 , simula vectores de varianzas con `replicate()` y analiza la distribución Chi-cuadrada.
5. **¿Se utiliza `set.seed()`?** Si **¿Por qué?** Para asegurarme de que salgan los mismos datos cada que se ejecuta la lección.

Actividad Integral:

1. **¿Qué objetos crea?** `n_total`, `tiempos`, `estado`, `logs_servidor`, `poblacion_tiempos`, `poblacion_exitos`
2. **¿Qué información contienen esos objetos?**
 - `n_total`: Un valor numérico entero (5000) que representa el tamaño total de la población de peticiones.
 - `tiempos`: Un vector numérico con 5000 valores generados mediante una distribución normal (Media 120, desviación estándar 15) redondeados a dos decimales, que simulan tiempos de respuesta en milisegundos.

- estado: Un vector binario con 5000 valores (1 exitoso, 0 error), generado con una probabilidad de éxito aproximada del 95%..
 - logs_servidor: Un data.frame poblacional con 5000 filas y 3 columnas (id_peticion, tiempo_ms y éxito).
 - poblacion_tiempos: Un vector numérico extraído de la columna tiempo_ms de logs_servidor.
 - poblacion_exitos: Un vector extraído de la columna éxito de logs_servidor.
3. **¿Por qué se inicializan antes de comenzar la lección?** Porque el código del initLesson.R se ejecuta automáticamente al iniciar la lección en swirl para cargar y dejar disponibles los datos poblacionales en RStudio. Esto excita que se tengan que crear los datos de forma manual cada vez que se hace el curso, así nos ahorramos tiempo todos.
 4. **¿En qué actividades se utilizan?**
 - poblacion_tiempos: Se utiliza en la toma de muestras de tiempos de respuesta (sample(poblacion_tiempos,, 30)) y en la simulación de las 1000 medias (simMedias) y 1000 varianzas muestrales (simVarianzas).
 - poblacion_exitos: Se utiliza en la simulación de las 1000 proporciones muestrales de éxito (simProporciones <- replicate(1000, mean(sample(poblacion_exitos, 30))))
 - logs_servidor: Se utiliza de forma de referencia teórica para identificar la población total en la primera pregunta de opción múltiple de la lección.
 5. **¿Se utiliza set.seed()? Si ¿Por qué?** Para asegurarme de que salgan los mismos datos cada que se ejecuta la lección, es lo mismo que con otras lecciones, en esta usamos rnorm y runif que simulan datos aleatorios.

Referencias utilizadas:

Emanuel:

- Economipedia. (2024.). *Muestreo aleatorio*. Economipedia.
<https://economipedia.com/definiciones/muestreo-aleatorio.html>
- Economipedia. (2022). *Muestreo por conveniencia*. Economipedia.
<https://economipedia.com/definiciones/muestreo-por-conveniencia.html>
- Economipedia. (2022). *Muestreo sistemático*. Economipedia.
<https://economipedia.com/definiciones/muestreo-sistematico.html>
- Economipedia. (2022.). *Población objetivo*. Economipedia.
<https://economipedia.com/definiciones/poblacion-objetivo.html>
- R Core Team. (2019). *seq: Sequence generation* (Versión 3.6.2) [Documentación de software]. R Documentation.
<https://www.rdocumentation.org/packages/base/versions/3.6.2/topics/seq>
- Lawson, B. L., & Leemis, L. M. (2021). *set.seed: Set seed for non-uniform random number generators* (Versión 2.0.1) [Documentación de paquete de R]. R Documentation.
<https://www.rdocumentation.org/packages/simEd/versions/2.0.1/topics/set.seed>
- Crump, M. J. C. (s. f.). *4.13: Estimación de parámetros poblacionales*. En *Responder preguntas con datos - Estadística introductoria para estudiantes de psicología*. LibreTexts Español.
[https://espanol.libretexts.org/Bookshelves/Estadisticas/Estadistica_Aplicada/Libro%3A_Responder_preguntas_con_datos_-_Estadistica_introductoria_para_estudiantes_de_psicologia\(Crump\)/04%3A_Probabilidad%2C_muestreo_y_estimaci%C3%B3n/4.13%3A_Estimaci%C3%B3n_de_par%C3%A1metros_poblacionales](https://espanol.libretexts.org/Bookshelves/Estadisticas/Estadistica_Aplicada/Libro%3A_Responder_preguntas_con_datos_-_Estadistica_introductoria_para_estudiantes_de_psicologia(Crump)/04%3A_Probabilidad%2C_muestreo_y_estimaci%C3%B3n/4.13%3A_Estimaci%C3%B3n_de_par%C3%A1metros_poblacionales)

Sergio:

- Thomas, L. (2023, June 22). Stratified Sampling | Definition, Guide & Examples. Scribbr. from <https://www.scribbr.com/methodology/stratified-sampling>
- Muguira, A. (2023, 23 junio). Muestreo estratificado, un tipo de muestreo de probabilidad. QuestionPro. <https://www.questionpro.com/blog/es/muestreo-estratificado>
- Thomas, L. (2023, June 22). Cluster Sampling | A Simple Step-by-Step Guide with Examples. Scribbr. from <https://www.scribbr.com/methodology/cluster-sampling/>
- Stewart, L. (2025, 11 febrero). Método de muestreo por conveniencia en la investigación. [Atlas.ti](https://atlasti.com/es/research-hub/muestreo-de-conveniencia#ventajas-del-muestreo-de-conveniencia)
<https://atlasti.com/es/research-hub/muestreo-de-conveniencia#ventajas-del-muestreo-de-conveniencia>

Gael:

- Hankin, R. K. S. (2020). var: Variance and covariance matrix (Versión 1.0-6) [Documentación de paquete de R]. RDocumentation. <https://www.rdocumentation.org/packages/cmvnorm/versions/1.0-6/topics/var>
- # R Core Team. (2019, 12 de diciembre). Chisquare: The Chi-Squared Distribution. R Documentation. <https://www.rdocumentation.org/packages/stats/versions/3.6.2/topics/Chisquare>
- Walpole, R. E., Myers, R. H., Myers, S. L., & Ye, K. (2012). *Probabilidad y estadística para ingeniería y ciencias* (9.^a ed.). Pearson Educación.
- # Sample: R Core Team. (2019). R: A language and environment for statistical computing (Version 3.6.2) [Manual de software]. R Foundation for Statistical Computing. <https://www.rdocumentation.org/packages/base/versions/3.6.2/topics/sample>
- # R-bloggers. (2023, 11 de julio). The replicate function in R. R-bloggers. <https://www.r-bloggers.com/2023/07/the-replicate-function-in-r/>

Distribución de actividades entre integrantes:

Al empezar el curso nos dividimos los 9 temas que había en 3, así cada uno se llevaba una misma parte. A Emanuel le tocaron los primeros 3, Sergio del 4 al 6 y a Gael del 7 al 9. La actividad integradora la hicimos los 3 juntos y ya cada quien hizo la parte del curso que le tocaba.

Evidencias de pruebas del curso:

Introducción al muestreo:

```
|=====| 18%
| Una empresa de software desea evaluar la latencia de una API que recibe 1,000,000 de peticiones al dia. Por
| limitaciones de almacenamiento, analiza unicamente 2,000 peticiones seleccionadas al azar. En este escenario, ¿que
| representa el millon de peticiones?

1: La muestra representativa
2: El marco muestral
3: El estadístico de interes
4: La poblacion objetivo

Selection: 4

| Your dedication is inspiring!

|=====| 27%
| Exacto. La poblacion (N) es la totalidad de elementos bajo estudio, mientras que la muestra (n) es un subconjunto
| medible. Para poder extraer una muestra probabilística, requerimos un 'marco muestral': una lista o mecanismo que
| identifique a todos los individuos de la poblacion.

| All that practice is paying off!

|=====| 91%
| Para inspeccionar rapidamente la cantidad total de elementos en tu poblacion finita, calcula la longitud de
| 'N_servidores' usando la funcion length().

> length(N_servidores)4
Error: unexpected numeric constant en "length(N_servidores)4"

> length(N_servidores)4
Error: unexpected numeric constant en "length(N_servidores)4"

> length(N_servidores)
[1] 50

| Your dedication is inspiring!

|=====| 100%
| Excelente! Has completado los conceptos base: distincion entre poblacion, marco muestral y los riesgos de sesgo
| inherentes al muestreo no probabilístico. En la siguiente leccion abordaremos el Muestreo Aleatorio Simple.
|
```

Muestreo aleatorio simple:

```
|=====| 25%
| Observa las primeras filas del data frame ejecutando head().

> head(poblacion_microservicios)
  id_servicio  tipo tiempo_ms
1           1   Auth    229.63
2           2   Auth    264.09
3           3   Auth    226.03
4           4 Billing    236.38
5           5   Auth    293.53
6           6 Catalog   217.79

| That's correct!

|=====| 31%
| En situaciones reales, el parametro poblacional (Como la media verdadera  $\mu$ ) es desconocido. Aqui contamos con
| 'media_verdadera' para contrastarla directamente contra las estimaciones que obtenemos mediante la muestra.

...

|=====| 38%
| El parametro poblacional desconocido o real en la practica aqui lo conocemos. Consulta la media de la poblacion
| imprimiendo la variable 'media_verdadera'.

> media_verdadera
[1] 240.99

|=====| 94%
| Observa el valor obtenido en tu consola comparado con 'media_verdadera'. ¿A que se debe la discrepancia numerica
| entre ambos valores?

1: A que el muestreo fue sesgado
2: A un error en el algoritmo de R Studio
3: Al error de muestreo natural inherente a estimar con un subconjunto  $n < N$ 
4: A que n debio ser exactamente igual a N para poder calcular la media

Selection: 3

| You nailed it! Good job!

|=====| 100%
| Excelente trabajo! Has implementado un Muestreo Aleatorio Simple en R, comparado el parametro con su estimador y
| comprendido el origen del error de muestreo.
```

Muestreo sistemático:

```
|=====| 23%
Exacto, k = 20. El siguiente paso en el muestreo sistemático 1-en-k es elegir un punto de arranque aleatorio 'A' estrictamente entre 1 y k (equiprobabilidad de origen).
...
|=====| 31%
Fijar una semilla con set.seed() asegura que la generación de números aleatorios sea reproducible. Esto garantiza que cualquier analista obtenga exactamente el mismo punto de arranque. (s.f ; Barry Lawson, Larry Leemis, Vadim Kudlay)
...
|=====| 38%
Fija la semilla en 10 con set.seed() para garantizar reproducibilidad.
> set.seed(10)
Great job!
```

```
|=====| 85%
La mayor vulnerabilidad del muestreo sistemático es la 'periodicidad': Si los datos presentan un patrón o ciclo repetitivo oculto que coincide con el intervalo k, la muestra capturará siempre el mismo comportamiento.
...
|=====| 92%
Supongamos que auditamos un servidor cuyo tráfico experimenta un pico cíclico de sobrecarga cada 20 transacciones. Si nuestro k = 20 coincide con esa periodicidad natural, ¿qué problema estadístico grave ocurre?
1: La varianza de la muestra se vuelve cero obligatoriamente
2: El muestreo se convierte automáticamente en un muestreo estratificado
3: El software lanzará un error de desbordamiento de memoria
4: Se introduce un sesgo sistemático severo en la muestra al capturar siempre el mismo punto del ciclo
Selection: 4
| That's correct!
|=====| 100%
Excelente! Has dominado el cálculo del intervalo k, la definición del arranque aleatorio A, la generación con seq() y la advertencia metodológica contra patrones cíclicos o periodicidad oculta.
```

Muestreo Estratificado:

```
|=====| 54%
Utiliza las funciones prop.table() y table() juntas para calcular la proporción de cada tipo de suscripción en la base de datos. Escribe el comando aplicado a la columna suscripcion de bd_usuarios.
> prop.table(table(bd_usuarios$suscripcion))
Admin Básico Pro
0.051 0.713 0.236
| All that practice is paying off!
|=====| 62%
Bien hecho, como notarás te dio el valor de proporción que representa cada tipo de suscripción, si quieres el valor en porcentaje solo tienes que multiplicarlos por 100. En este caso, los admin son el 5.1%, los básicos son el 71.3% y los pro son el 23.6%
```

```
|=====| 92%
Ahora que tu estrato está aislado en 'usuarios_pro', extrae una muestra aleatoria de 15 de estos usuarios usa la función sample() sobre la columna 'id' del objeto que acabas de crear y guárdala en una variable llamada 'muestra_pro'
> muestra_pro <- sample(usuarios_pro$id, 15)
| You are really on a roll!
|=====| 100%
¡Excelente! Has aislado exitosamente un estrato y seleccionado una muestra aleatoria dentro de él. En un proyecto real, repetirías este mismo proceso para los usuarios 'Básico' y 'Admin' ¡Con esto terminamos el Muestreo Estratificado!
```

Muestreo Conglomerado:

```
|=====| 27%
Imagina que quieres evaluar el rendimiento de una red de bases de datos distribuidas. Tienes 50 servidores y cada uno procesa miles de transacciones. En lugar de tomar algunas transacciones de los 50 servidores (lo cual sería muy costoso y tardado), seleccionas 5 servidores completos al azar y analizas TODAS las transacciones dentro de ellos. Aquí, cada servidor funciona como un conglomerado.
...
|=====| 36%
En el ejemplo de los servidores, ¿por qué este método es Muestreo por Conglomerados y NO Muestreo Estratificado?
1: Porque seleccionamos algunos servidores completos y evaluamos todo en su interior.
2: Porque tomamos un número de transacciones de cada uno de los 50 servidores.
3: Porque seleccionamos las transacciones más rápidas.
Selection: 1
| Your dedication is inspiring!
|=====| 45%
Imagina que tienes una base de datos llamada 'bd_transacciones' con 50 registros. Estos registros provienen de 5 servidores distintos (10 transacciones por servidor: Server_A, Server_B, Server_C, Server_D y Server_E).
```



```
|=====| 91%
| Si revisas tu 'muestra_final' que acabas de extraer, ¿cuántas transacciones tendrías en total?

1: Solo 2 transacciones.
2: 50 transacciones.
3: 20 transacciones (las 10 de Server_A más las 10 de Server_C).

Selection: 3

| You got it right!

|=====| 100%
| Con esto haz llegado al final de la leccion. Primero tomaste al azar algunos grupos de la población(Conglomerados), y despues uniste todos sus elementos en una sola muestra.
```

Muestreo Por Conveniencia:

```
|=====| 71%
| ¿Crees que estos resultados representen bien a una poblacion, o crees que los resultados esten sesgados?

1: Los resultados representan a una población y sirven para inferir una conclusión
2: Los resultados pueden tener un sesgo por la hora o lugar en que se realizaron.

Selection: 2

| Your dedication is inspiring!

|=====| 76%
| Veamos que pasa si sacamos el promedio de los 1000 registros en la base de datos

...

|=====| 82%
| Usa de nuevo la función mean(), pero esta vez aplícala a toda la población original. en la base de datos 'respuestas' y solicitando el registro 'calificacion_producto'.

> mean(respuestas$calificacion_producto)
[1] 2.117
```

```
|=====| 94%
| Viendo estos resultados, ¿por qué crees que los primeros 50 en contestar el QR le dieron una calificación tan alta en comparación con el resto?

1: Porque los primeros 50 siempre tienen la razón.
2: Porque el poste con el QR podría haber estado pegado afuera de una tienda exclusiva para fans del producto, atrayendo o a gente entusiasta.
3: Porque R se equivocó al calcular el promedio.

Selection: 2

| That's a job well done!

|=====| 100%
| Así es!. Has demostrado como un muestreo por conveniencia puede arrojar resultados completamente sesgados si no se tiene cuidado. Hemos llegado al final de esta leccion
```

Test Comparativo:

```
|=====| 27%
| 2. Quieres saber la opinión sobre la cafetería de la universidad. Divides a los estudiantes por carrera y eliges al azar a 5 alumnos de cada una. Qué método es?

1: Muestreo Estratificado
2: Muestreo Sistemático
3: Muestreo por Conveniencia

Selection: 1

| Excellent job!

|=====| 36%
| Bien! En el muestreo Estratificado, divides a la población en grupos (estratos) y te aseguras de tomar muestra de algunos individuos de absolutamente todos los grupos para que estén representados.
```

```
|=====| 64%
| 4. Necesitas probar la comodidad de un nuevo modelo de teclado. Para acabar rapido tu tarea, se lo das a probar unicamente a los tres amigos que están sentados contigo en la biblioteca. Qué muestreo utilizaste?

1: Muestreo Sistemático
2: Muestreo Aleatorio Simple
3: Muestreo por Conveniencia

Selection: 3

| You got it!

|=====| 73%
| Así es! Usaste el Muestreo por Conveniencia. No hubo selección matemática ni aleatoria; tomaste la muestra basandote exclusivamente en la facilidad, rapidez y accesibilidad.
```

Distribución muestrales de media y proporción:

```
|=====| 19%
| En tu entorno cuentas con el vector 'poblacionTiempos',
| extrae una muestra aleatoria de tamaño n = 30 y calcula su
| media. Usa las funciones mean() y sample().
>
> mean(sample(poblacionTiempos,30))
[1] 258.3157

| That's a job well done!

|=====| 22%
| Si repites ese comando, el resultado cambiara
| ligeramente debido al error muestral, pero para
| visualizar la distribucion de todas las medias
| posibles, simulemos 1000 muestras.
...

|=====| 96%
| Que sucede con la variabilidad (error estandar) de ambas
| distribuciones muestrales a medida que aumentamos el
| tamaño de muestra n?
1: La variabilidad aumenta considerablemente.
2: La variabilidad permanece exactamente igual sin importar el
tamaño de n.
3: La variabilidad disminuye, haciendo que las estimaciones se
an mas precisas.
Selection: 3

| That's a job well done!

|=====| 100%
| Felicidades! Has completado con exito la leccion sobre
| Distribuciones Muestrales. En la siguiente leccion
| profundizaremos en el tema de: 'Distribucion muestral de
| la varianza'.
```

Distribución muestral de la varianza:

```
|=====| 27%
| Porque dividimos entre (n-1) y no entre n al calcular S^2
| en una muestra?
1: Porque perdemos dos grados de libertad al calcular la media
na.
2: Porque usar (n - 1) convierte a S^2 en un estimador insesga
do de sigma^2.
3: Porque (n - 1) se utiliza unicamente cuando n es mayor a 10
00.
Selection: 2

| Excelllent work!

|=====| 50%
| Forma teorica de la distribucion (Chi-cuadrada): A
| diferencia de la media (que se distribuye Normal), la
| variable transformada (n - 1)*s^2 / sigma^2 sigue una
| distribucion Chi-cuadrada con (n - 1) grados de libertad.
...

|=====| 53%
| Cuantos grados de libertad (df) tiene la distribucion
| Chi-cuadrada teorica para nuestras muestras de n = 25?
1: 50 grados de libertad (2n).
2: 25 grados de libertad (n).
3: 24 grados de libertad (n - 1).
Selection: 3

|=====| 97%
| Si el valor de 'chi_obs' resulta menor
| que qchisq(0.95, df = 29), ¿que
| diagnostico das sobre el desempeño del
| servidor?
1: El servidor debe ser reiniciado inmediatamente por exceso de
sesgo.
2: El servidor cumple con el SLA de variabilidad al 95% de conf
ianza.
3: El tamaño de muestra n = 30 invalida el modelo Chi-cuadrado.
Selection: 2

| That's a job well done!

|=====| 100%
| Bien hecho, con esto terminamos la
| leccion 9 y con eso la ultima leccion
| de todo este curso. Ahora lo ultimo
| que te queda es hacer la actividad
| integradora con todo lo que has visto
| en las anteriores lecciones. Suerte.
```

Aplicación Integral

```
| El muestreo sistematico aplica un intervalo regular k para la seleccion.
1: Muestreo por conglomerados.
2: Muestreo sistematico.
3: Muestreo aleatorio simple.
Selection: 2
| Keep up the great work!
|=====| 32%
| Cual es la diferencia principal entre el muestreo por conglomerados y el muestreo por conveniencia?
1: Ambos son metodos de seleccion no probabilistica sin aleatoriedad.
2: Conglomerados divide en grupos naturales no homogeneos y conveniencia es no probabilistico.
3: Conglomerados selecciona solo a los elementos mas faciles de acceder.
Selection: 2
| All that practice is paying off!
|=====| 36%
| Cual es la justificacion adecuada para elegir el muestreo aleatorio simple en este analisis de logs?
1: Garantiza equiprobabilidad de seleccion y evita el sesgo en las estimaciones del servidor.
2: Es el unico metodo que no requiere instalar paquetes adicionales en R.
3: Permite seleccionar unicamente las peticiones generadas en horario laboral.

|=====| 93%
| Calcula el promedio de tus proporciones simuladas.
> mean(simProporciones)
[1] 0.9536333
| You are amazing!
|=====| 96%
| Al comparar 'mean(simProporciones)' con la proporcion real de exitos. Que propiedad de la distribucion de la
| proporcion se confirma?
1: La proporcion muestral siempre genera un sesgo positivo.
2: El tamaño de muestra invalida la estimacion de proporciones.
3: La proporcion muestral es un estimador insesgado de la proporcion poblacional.
Selection: 3
| You got it!
|=====| 100%
| Excelente trabajo, has completado exitosamente la Actividad Integradora del curso y con eso completaste todo el curso
| felicidades.
```

Reflexión final:

Emanuel:

1. ¿Qué aprendiste sobre muestreo durante el desarrollo del proyecto?

Pues retomé los conceptos básicos de probabilidad y estadística, creo que fue una buena refrescada de memoria sobre los temas.

2. ¿Qué diferencia consideras más importante entre los distintos métodos de muestreo?

En los temas que me tocan siento que la diferencia más importante es que, en todos tienen la misma probabilidad de ser elegidos, pero en el sistemático todos están condicionados al primero.

3. ¿Qué comprendiste sobre las distribuciones muestrales?

Que son la manera en como los datos se comportan en todas las muestras.

4. ¿Qué función cumplió initLesson.R dentro del curso?

Hacer que el alumno no tenga que estar batallando en escribir código que pueda ser frustrante para él o bien no aporte nada.

5. ¿Qué dificultades técnicas encontraste?

Varias veces intentaba verificar respuestas y no salían, aunque las escribiera igual, el error estuvo en que actualizaba el yaml pero tenía que volver a instalar la lección para que asimile los cambios y ahora si avanzaba.

6. ¿Cómo contribuiste al trabajo del equipo?

Haciendo las primeras 3 partes y estar al pendiente de los comentarios de mis compañeros sobre que cambiar o que podía ser explicado de otra manera.

7. ¿Qué mejorarías en una segunda versión ?

Utilizar en todas mis lecciones el initLesson y solo ir guiando al alumno para un examen final.

Sergio:

1. ¿Qué aprendiste sobre muestreo durante el desarrollo del curso?

No conocía los problemas que pueden surgir en el muestreo por conveniencia, al no tomar en cuenta cosas como, el lugar donde se toma la muestra, el público o incluso la hora a la que se hace.

2. ¿Qué diferencia consideras más importante entre los distintos métodos de muestreo?

Entre el muestreo estratificado y conglomerado, es fácil confundirlo si no se entiende que en el conglomerado se toman algunas muestras de todos los subgrupos (llamados estratos) y en el conglomerado se toman la muestra completa solo de algunos subgrupos

3. ¿Qué comprendiste sobre las distribuciones muestrales?

Comprendí que una distribución muestral nos ayuda a entender cómo se comportan los datos cuando extraemos múltiples muestras de una misma población.

4. ¿Qué función cumplió initLesson.R dentro del curso?

Fue muy útil ya que sin este no podríamos haber sabido que datos le iban a salir al usuario cuando aplicara promedios u otras funciones

5. ¿Qué dificultades técnicas encontraste?

En un momento del desarrollo me encontré con un problema de rutas ya que por alguna razón Onedrive “secuestro” la carpeta donde tenía guardado el proyecto y no podía ejecutar ningún tipo de código no solo en R, también con código de python y c.

6. ¿Cómo contribuiste al trabajo del equipo?

Realice las lecciones de los temas 4 al 6, contribuí con las preguntas que comparan los tipos de muestreo y colabore con la actividad integradora

7. ¿Qué mejorarías en una segunda versión?

Mejoraría el uso de github ya que recién me estoy familiarizando con su uso, haría más uso de los commits para guardar el progreso del curso

Gael:

1. ¿Qué aprendiste sobre muestreo durante el desarrollo del curso?

En esta práctica con lo referente a muestreo aprendí a como usar código R para seleccionar y analizar muestras utilizando métodos probabilísticos y no probabilísticos.

2. ¿Qué diferencia consideras más importante entre los distintos métodos de muestreo?

Si la selección es aleatoria o no aleatoria. De esto depende el método que se use para encontrar el resultado al problema en cuestión.

3. ¿Qué comprendiste sobre las distribuciones muestrales?

Comprendí que una distribución muestral es el comportamiento teórico que siguen los estimadores (Como la media, la proporción y la varianza) cuando se extraen muchas muestras del mismo tamaño de una población.

4. ¿Qué función cumplió `initLesson.R` dentro del curso?

Ser una mano ayudante que definir e inicializar varias variables que se necesitarían en algunas partes de las lecciones que hicimos.

5. ¿Qué dificultades técnicas encontraste?

Muchas, más que nada problemas tontos de R, hubo uno que la verdad no entendí del todo porque se rompía, pero me tomó un buen rato aun usando google el poder resolver ese error, porque no era de mi código como tal, era algún problema que R tenía. De ahí en más, eran simplemente pequeños errores de que me faltara poner “”, o ‘.’ y así.

6. ¿Cómo contribuiste al trabajo del equipo?

Haciendo las últimas 3 lecciones, ayudar a crear la actividad integradora, y diría que ayudar a hacer los documentos, a darles forma al menos para que se vieran bien.

7. ¿Qué mejorarías en una segunda versión?

Al menos en mi parte de las lecciones, diría que las definiciones, explicar más a detalle qué es cada cosa, aun si yo trate de explicar a detalle todo lo que hable.